

갑자기 MSE, cross-entropy 그냥쓰다가 왜?? 라는 의문점때문에 자세히 정리함

MSE $\rightarrow (y - \hat{y})^2$

• 예측값 자체를 정답값에 맞추기 위한 Loss

• 유용 $\begin{cases} \text{회귀, 좌표, 길이} \\ \text{문도, 위치} \end{cases}$ (연속값)

Cross Entropy $\rightarrow H(P, Q) = -\sum_i P(i) \log Q(i)$

• 정답 class의 확률을 최대화 하기 위한 Loss

• 정답 class의 확률 $P(y)$ 를 최대화 하는게라면 단순히 $P(y) - P(\hat{y})$ 하면 안되나? 싶었는데

정답인데 $P(y)=0.0001$ 과 같은 애들에게 과대실리를 강하게 주고싶어함.

비교

단순 차이		$-\log(P(y))$	
$P(y)$	$1 - P(y)$	$P(y)$	$-\log(P(y))$
0.9	0.1	0.9	0.1
0.5	0.5	0.5	0.69
0.1	0.9	0.1	2.3
0.01	0.99	0.01	4.6
0.0001	0.9999	0.0001	9.2

$-\sum_i P(i) \log Q(i)$

• 그러면 $\log Q(i)$ 만 다 더하면 안되나? 왜 $P(i)$ 를 곱하게? 생각이드는데

애초에 엔트로피에서는 $P(i)$ 가 정보량의 평균(기대값)을 계산할때 사용함

크로스 엔트로피에서는 $P(i)$ 가 실제 데이터 분포를 나타내는 가중치이다.

ONE-HOT 분포에서는 $P(i)$ 가 정답 클래스만 선택하도록 마스킹 역할을 함.

정답 클래스의 예측 확률만 곱하게 하고 나머지는 무시 하기 위해서 이다.

예) 예측 = $[0.99, 0.01]$, 정답 = $[1, 0]$

• 인접한 $P(i)$ 로 배제하면 정답로 맞췄고 loss가 매우크다

결과 = $-\log 0.99 - \log 0.01 = 4.6$

• $P(i)$ 를 넣으면

결과 = $-(1 \log 0.99 + 0 \log 0.01) = 0.01$ 작아진다

KL-Divergence 이해하기 ① - 정보량

• 정보량이란

- ① 어떤 사건이 발생했을 때 내가 얼마나 놀랐는가
- ② 그 사건을 알게 됨으로써 새롭게 얻은 정보의 양
- ③ 얼마나 예상 밖의 사건이었을 수직으로 나타낸 것

• 정보량의 수식은 왜 $-\log P(x)$ 로 정의 하는가?

※ 어떠한 함수 $I(P)$ 를 만들어서 사건이 발생했을 때의 정보량을 얻고 싶었다. 정보량을 얻기 위한 공식은 생각하면 좋을 아래 조건을 만족하는 수식을 찾았다.

조건① 확률이 작을 수록 정보량이 커져야 한다.

예)	해뽕	도둑	→	$P_1 < P_2$ 도둑 < 해뽕	+	$I(P_1) > I(P_2)$ 도둑 정보량 > 해뽕 정보량
확률	0.9	0.1				

조건② 확실한 사건은 정보량이 '0' 이어야 한다.

예) 해가 뚱쪽에서 뜬다 $= P = 1.00$

$$I(P) = I(1.00) = "0"$$

조건③ 독립사건은 정보량이 더해져야 한다. → 다음은 예시에서 설명

예) 주사위를 두 번 던지는 상황

각각 확률은 $\frac{1}{6}$, 정보량이 A 값이라고 가정하자

두 번 주사위 던졌다고 첫 번째 정보량은 ① 두 번째 정보량은 ② 라고 못한다 (독립이니까)

그래서 정보량을 나타내는 함수 ① 가 존재 하면 아래 수식처럼 되어야 한다.

$$I\left(\frac{1}{6} \times \frac{1}{6}\right) = I\left(\frac{1}{6}\right) + I\left(\frac{1}{6}\right) = ① + ① \rightarrow \log \text{량 딱 맞다!!}$$

↳ 독립하면 종속 사건은 점이다.

만약 A 확률에 B가 영향을 받는 상황에서 정보량을 나타내는 공식 사용 하면

$$I(A, B) = I(A) + I(B|A) = A \text{ 정보량} + A \text{ 영향 받은 } B \text{ 정보량}$$

• KL-Divergence란

① 실제 분포 P를 설명해야 하는데, 잘못된 Q를 사용했을 때 평균적으로 얼마나 더 많은 정보가 필요한가"를 의미한다.

↳ KL 값이 크다 → Q와 P가 많이 다르다 → 정보 양이 크다.

• 예시 설명

가정) 실제 세상의 확률 분포는 $P = [0.1, 0.2, 0.1]$ → 정보량 $= -\log P(i)$

내가 믿는 확률 분포 $Q = [0.4, 0.3, 0.3]$ → 정보량 $= -\log Q(i)$

→ 둘의 차이 $= (-\log P(i)) - (-\log Q(i))$

$$= \log Q(i) - \log P(i)$$

$$= \log \frac{Q(i)}{P(i)}$$

= Q를 믿어서 발생한 추가 비용 (정보 손실)

• 한 사건 말고 전체의 평균을 본다면 (평균 정보 손실)

$$\sum_i P(i) \log \frac{P(i)}{Q(i)}$$

확률야인가? 그래서 식이 확률 x 확률 야인가?

$\log \frac{P(i)}{Q(i)}$ 는 위에서 말했지만 '정보 손실 값'이기 때문에 아래처럼 표현 가능 하다.

→ 클레소 ①에서의 정보 손실 $\log \frac{0.1}{0.4}$, 클레소 ②에서 나올 확률 0.1

" ② " $\log \frac{0.2}{0.3}$, " ② " 0.2

" ③ " $\log \frac{0.1}{0.3}$, " ③ " 0.1

↳ 여기서 나올 확률이 이거야! 그래서 전체 평균 손실은

$$\sum_i P(i) \log \frac{P(i)}{Q(i)}$$

[illegible]