

Lane Net

소개

- 차선 인식에 특화된 모델이다.
- CNN과 RNN을 결합한 구조를 사용한다.
- 차선의 픽셀 수준 세그멘테이션과 차선의 인스턴스 분리를 동시에 수행한다.
- 차선의 형태와 위치를 정확하게 인식하며, 다양한 도로 상황에 잘 적용한다. (실선, 파선, 단선, 이중선 등)

과정

1) IPM (Inverse Perspective Mapping)

- 이미지 전처리 과정이다.
- 카메라에는 원근법이 적용되어 차선을 직선으로 보기 어렵다. 이 문제를 해결한다.

2) Lane edge proposal network (encoder - decoder)

- 픽셀 단위로 차선의 edge 부분인가 아닌가를 2진분류하는 네트워크

3) Lane line Localization network (LSTM) (encoder-decoder)

- 이 픽셀이 차선 이다 아니 다를 숙정한다.

2,3번과정으로 나뉘는 이유




- ① 신경망의 특성인 '블랙박스' 특성을 완화 시킬수있다.
- ② 데이터가 무조건 일직선일 필요가 없다.
- ③ 차원 축소가 잘 이루어진다.
- ④ 운전 보조 시스템의 전체 계산 비용을 줄일수있다. (저자의 개인적인 의견)

IPM

- bird's eye view

• 원근감으로 인해 카선이 직선으로 보이지 않는 문제를 해결한다.

• 변환 방법은 두가지가 있다.




→ 맨 위의 평면 픽셀을 늘리는 방법은 확실한 방법이지만

시야각을 줄이고 중앙좌선 이외의 경로를 추적할수 없다.

→ 상대적으로 해상도가 낮은 상단 가장자리 외 원 이미지에서

사용 가능한 모든 픽셀을 보존 하에 때문에 나온 방법으로 여겨짐

Lane edge Proposal network




• 픽셀단위로 도로의 edge를 출력하는 과정이다.

• edge복합을 '1'로 나타낸다.

Segmentation 파트 DeePLeap v3+에
Depth-wise Convolution 설명함 거기에
(1x1xC) Convolution을 진행한것이다.


- encoder



- encoder 부분에 Depth-wise separable convolution을 적용하여

일반적인 Convolution 보다 연산량을 줄였다.

- Deconvolution



- decoder 부분에서는 sub-pixel-convolution-layer를 사용하였다.

덕분에 기존의 Deconvolution Layer가 가지고 있던 단점 (학습이 힘들다)을 극복하고

피쳐 해상도를 점진적으로 복구하였다.

$$\frac{\sum y_i}{W \times H - \sum y_i}$$

→ 동적 가중치, negative Points에 대한 Positive Points의 비율

- Loss Function


$$\mathcal{L}_{ds} = \sum_i^B \sum_n^k y_n^i \cdot \log p_n^i + \beta (1 - y_n^i) \times \log (1 - p_n^i)$$

→ 배치 사이즈

→ 이미지에서 n번째 픽셀


→ 이미지에서 n번째 Positive Point

Lane line localization network




- Input으로 위에서 만든 이미지에서 가장자리 점의 좌표를 넣어준다.
- 점의 좌표값만 Input으로 넣어 학습속도에 큰 영향을 가져 왔다.
- 이후 1Dconv와 Pooling등과 같은과정을 거친다.
- 이렇게 나온 데이터를 LSTM에 넣어서 불확실한 차선 문제를 해결하였다.
- LSTM을 거쳐 나온 값이 '암계값'을 넘지 못하면 그림처럼 차를 'stop'시킨다.

-Loss Function



- 이미지를 3등분으로 나누고 예측한 x좌표를 $[k_1, k_2, k_3]$ 로 만든다.
- 이후 행렬식의 뺄아 $[P_0, P_1, P_2]$ 에 계속값을 넣어준다.
- 마지막으로 정답 x좌표와 $[P_0, P_1, P_2]$ 사이의 거리를 Loss Function으로 이용한다.

성능



- 기계에 따른 FPS

Table 1. Experiment results.

Difficulty	Easy (1170 lanes)			Hard (1035 lanes)		
	Detected	TPR	FPR	Detected	TPR	FPR
Junhwa et al. [6]	916	78.2%	9.5%	801	77.4%	15.9%
LaneNet	1146	97.9%	2.7%	1001	96.7%	3.9%

- 성능비교를 위해 'Multi-lane-detection'을 사용하였다.
- 차선 1개를 여러개로 예측하면 FPR (False positive rate)가 증가하고
- 차선 1개를 한 개로 예측하면 TPR (True positive rate)가 증가하게된다.

Table 2. Performance improvements by the weakly supervised loss function and additional weakly labeled samples.

Difficulty	Easy (1170 lanes)			Hard (1035 lanes)		
	Detected	TPR	FPR	Detected	TPR	FPR
Baseline	996	83.1%	3.4%	904	82.1%	7.7%
Weak supervision	1129	96.4%	2.8%	932	90.0%	5.1%
Weak supervision + Tuning on weakly labeled data	1146	97.9%	2.7%	1001	96.7%	3.9%

- 일반적으로 이미지를 둘로 했을 때 보다
- 이전 분류 하고 했을 때 TPR값이 높았다.