

Deep Lab

들어가기전


- 구글이 제시한 모델이다.
- 2015년 부터 업데이트 하고있고 Segmentation 중에 상위권에 포함한다.
- 모델은 계속하면서 조금씩 추가 해간다.

종류


- DeepLab V1 = Atrous convolution 을 처음 적용하였다.
- DeepLab V2 = multi-scale context를 적용하기 위한 Atrous Spatial Pyramid Pooling (ASPP) 제안
- DeepLab V3 = ResNet73의 Atrous convolution 을 활용
- DeepLab V3+ = Depthwise separable convolution 과 Atrous convolution 을 결합한 Atrous separable convolution 제안

아키텍처

Xception



DeepLab V3+



- 비교했을때 더 깊고
- Max Pooling을 stride가 있는 Depthwise separable convolution으로 바꿨다.
- 3x3 Depthwise convolution 후에 Batch Norm 과 ReLU를 더해줬다.

training

- Image Net 데이터 사용
 - Pre-trained ResNet-101, modified aligned Xception을 backbone network로 사용
 - 초기 learning rate = 0.007
 - 이후 learning rate는 점점 줄어드는 'poly' learning rate policy 사용
- $$(1 - \frac{iter}{max_iter})^{power}$$
- Crop size = 513x513 (top image를 사용한다)
 - Batch normalization = batch size = 6 사용

성능

Backbone Decoder ASPP Image-Level mIOU	Method	Coarse	mIOU
X-65 ✓ ✓ ✓ 77.33	ResNet-38 [83]	✓	80.6
X-65 ✓ ✓ ✓ 78.79	PSPNet [24]	✓	81.2
X-65 ✓ ✓ ✓ 79.14	Mapillary [86]	✓	82.0
X-71 ✓ ✓ ✓ 79.55	DeepLabv3	✓	81.3
	DeepLabv3+	✓	82.1

(a) val set results

(b) test set results

Table 7. (a) DeepLabv3+ on the Cityscapes val set when trained with train_fine set. (b) DeepLabv3+ on Cityscapes test set. Coarse: Use train_extra set (coarse annotations) as well. Only a few top models are listed in this table.


Atrous convolution

- 사용하는 이유


- classification과 object detection에서 사용되는 신경망들을 semantic segmentation에 적용하는 경우 여러번의 conv와 pooling 때문에 미세한 정보가 줄어들고 특성어 점점 축소화되는 단점이 있다.
- FCN인 경우 skip layer 통해 위에서 지정한 문제를 해결하였다. 하지만 skip layer 때문에 receptive field가 고정되어 다양한 scale의 object에 대응하기 힘들다는 단점이 있다.

- 아래 그림처럼 필터 사이에 공간을 주어 기존의 Convolution과 동일한 양의 파라미터를 사용해 계산량은 유지하고 receptive field는 커졌다.

- 한마디로 기존의 conv의 파라미터의 계산량 유지하지만 줄어보는 범위 receptive field가 크다.




- 기존의 방법과 비교



Atrous Spatial Pyramid Pooling (ASPP)


- feature map로부터 확장 비율(dilation rate, r)이 다른 Atrous convolution을 병렬로 적용한 뒤 다시 합쳐준다.



- ASPP를 활용하면 다양한 크기의 feature map을 뽑아내 섞어서 활용할 수 있다.
- Receptive field가 정해져있어 작은 물체가 무시되거나 이상하게 인식되는 FCN과 비교했을 때 객관적으로 관측은 접근법이다.


Depthwise separable convolution

- 기존의 Convolution



- 하나의 필터가 RGB 3개의 색상에서 다 적용되어서 각 채널 별 가지고 있는 spatial feature를 얻기 힘들다.
- conv가 깊어질수록 연산량이 증폭한다.
- ④ 3채널 feature map을 얻고 싶을 때 $(K \times K \times (X \times M))$ 개의 파라미터의 개수가 필요하다.

- 해결하기 위해 Depthwise convolution 이 한 것



- 각 channel마다 spatial feature를 추출한다.
- 각 channel마다 하나의 spatial feature를 뽑아보니 식에 변화가 생긴다.
- ⑤ 3채널 input을 주면 $(K \times K \times 3)$ 개의 파라미터만 필요해진다.
- 기존 연산과 비교하면 사용하는 파라미터 수와 연산량을 획기적으로 줄일 수 있다.

기존에 M개만큼 실행해야 하는 연산

Xception

- pretrain된 모델을 사용하거나 transfer Learning을 사용하는 모델들을 보면 back bone이 되는 CNN이 몇개 있다 그 중에 한개이다.

• VGG, ResNet, Inception, Xception

들어가기 전

- 2017년 구글이 발표, 구글의 Inception-V3 모델보다 성능이 좋다.

• Encoder-Decoder 형태의 모델들에서 pretrain 된 Xception 모델이 Encoder로 작곡쓰인다.

• 핵심인 modified depthwise separable convolution의 개념이 쉬워 다른 모델에 적용하기 쉽다.

• Extreme ⊕ Inception에서 나온 만큼 Inception 모델이 기본이 된다.

Inception

- Inception-ResNet V2

- 목적


• 딥러닝은 많이 깊을수록, 레이어가 많을수록 성능은 좋지만 overfitting & vanishing gradient 문제가 생긴다.

• 위와같은 문제 때문에 Convolution 레이어를 sparse 하게 연결하면서 행렬 연산은 dense 하게 처리하기 위해 고안한 모델이다.

↳ Conv 레이어를 드문드문 연결하였다.

↳ '더 쉽게'

- 다른 모델과 비교



• 다른 모델에 활용하기에는 복잡해서

연산량과 파라미터가 많은 VGG보다 덜 사용된다.

• 다른 모델은 순서대로 conv를 진행 하지만 여기서는 동시에 conv를 진행한다.

이렇게 하면 Parameter의 개수도 줄어듦 연산량도 줄일수 있다.

• kernel size가 늘어날수록 연산량의 크기가 커져서 (5x5)conv를 (3x3) → (1x1)(1x3)으로 2번하는 방향으로 튜다.

• Residual Net 구조를 보며 (1x1)conv를 추가해서 특징을 더 자세히 보면서 연산량도 줄인것을 보여준다.

이걸 사용하면 빠리수렴 하는 것을 볼수 있다.






Figure 3. Optimal version of ResNet connections by (1) to (4) model configurations.

Xception 모델 아키텍처

- 중점

① Modified Depthwise Separable Convolution 사용

② VGG처럼 네트워크 구조가 간단해서 활용도가 높다.



모든 Conv layer 다음에는 -> Batch Normalization