

Efficient Net

-들어가기전 핵심

- 일반적으로 모델의 정확도를 높일때 (1)모델의 깊이 (2)너비 (3)입력 이미지의 크기를 조절한다.
- 논문에서는 3가지를 효율적으로 조절할 수 있는 **Compound Scaling** 방법을 제안한다
- Compound Scaling** 방법은 깊이, 너비, 입력 이미지 크기가 일정한 관계가 있다는 것을 실험적으로 찾아내고, 관계를 수식으로 만든다.
- 위와같은 방법으로 NAS구조를 수정하여 SOTA를 달성했다
- ResNet, mobileNet 등 CNN 기반 구조에도 효과가 있다.





Figure 1. Model Size vs. ImageNet Accuracy. All numbers are for single-crop, single-model. Our EfficientNets significantly outperform other ConvNets. In particular, EfficientNet-B7 achieves new state-of-the-art 84.3% top-1 accuracy but being 8.4x smaller and 6.1x faster than GPipe. EfficientNet-B1 is 7.6x smaller and 5.7x faster than ResNet-152. Details are in Table 2 and 4.

Model Scaling

- 일반적인 baseline에서 성능을 높이는 방법은 아래 세가지정도이다.



- baseline에서 입력값은 각 레이어 함수(F)를 거쳐서 최종 출력값을 생성한다.

$$N = F_k \odot \dots \odot F_2 \odot F_1(X_1) = \bigodot_{j=1 \dots k} F_j(X_1).$$

- 이렇게 나온 출력값 N 을 일반화시키면

$$N = \bigodot_{i=1 \dots 8} F_i^{r_i}(X(H_i, W_i, C_i))$$

- 여기에서 각 레이어에서 수행하는 연산(F)을 고정하고, 레이어수, 채널수, 입력 이미지 크기에 집중하여 확인한다.

- 다래에 수식예 (W), (D), (R) 상수가 생겼다. 이 상수들의 관계를 연구한 것이 **Efficient Net**이다.




Figure 2. Scaling Up a Baseline Model with Different Network Width (w), Depth (d), and Resolution (r) Coefficients. Bigger networks with larger width, depth, or resolution tend to achieve higher accuracy, but the accuracy gain quickly saturates after scaling 80%, demonstrating the limitation of single direction scaling. Baseline network is described in Table 1.

- w, d, r 에 따른 정확도 값이다.
- 그림을 보면 w, d, r 이 일정값이상이면 정확도가 빠르게 saturate 한다.
- w, d, r 이 낮을 때는 약간만 값을 조절해도 효과가 크다.
- w, d, r 중 하나만 조절 하는 것보다 w 와 r 을 함께 조절하여 최고 효율을 찾아내는 것이 **Compound Scaling**이다.

Compound Scaling

$$\begin{aligned} \text{depth: } d &= \alpha^{\beta} \\ \text{width: } w &= \beta^{\gamma} \\ \text{resolution: } r &= \gamma^{\delta} \\ \text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 &\approx 2 \\ \alpha \geq 1, \beta \geq 1, \gamma \geq 1 \end{aligned}$$

- α, β, γ 는 *Small grid search*로 결정되는 상수이다.
- γ 는 주어진 연산량에 따라 사용자 결정하는 상수이다.
- FLOPs는 너비와 해상도에 따라 제곱 배상승 한다.

연산속도 측정

로당복통 최적 연산횟수

- 논문에서는 $(\alpha \beta^2 \gamma^2) = 2$ 로 제한하고 제한된 범위에서 찾는 것이다.
 - w, d, r 중에 하나만 조절 하려 않고 2개씩 함께 조절하여 최고의 효율을 찾아낸다.
- 실제로 실험해보니 같이 하는 것이 성능이 더 좋았다.




Figure 3. Scaling Up EfficientNet-B0 with Different Methods.

Table 1. Scaled Models Used in Figure 3.

Model	FLOPs	Top-1 Acc.
Baseline MobileNetV1 (Howard et al., 2017)	1.0B	70.6%
Scale MobileNetV1 by width (w=2)	1.0B	74.2%
Scale MobileNetV1 by resolution (r=2)	1.0B	72.7%
Compound Scaling (d=1.4, w=1.2, r=1.3)	1.0B	75.6%

- 다른 모델에 적용시켰을 때


- 모바일 V2 와 레즈넬 두개에다가 했을 때 비슷한 FLOPs 에 높은 ACC 를 얻었다.

Table 3. Scaling Up MobileNets and ResNet.

Model	FLOPs	Top-1 Acc.
Baseline MobileNetV1 (Howard et al., 2017)	0.6B	70.6%
Scale MobileNetV1 by width (w=2)	2.3B	74.2%
Scale MobileNetV1 by resolution (r=2)	2.3B	72.7%
compound scale (d=1.4, w=1.2, r=1.3)	2.3B	75.6%
Baseline MobileNetV2 (Sandler et al., 2018)	0.3B	72.0%
Scale MobileNetV2 by depth (d=1)	1.2B	76.8%
Scale MobileNetV2 by width (w=2)	1.1B	76.6%
Scale MobileNetV2 by resolution (r=2)	1.2B	74.8%
MobileNetV2 compound scale	1.3B	77.4%
Baseline ResNet-50 (He et al., 2016)	4.1B	76.0%
Scale ResNet-50 by depth (d=1)	16.2B	78.1%
Scale ResNet-50 by width (w=2)	14.7B	77.7%
Scale ResNet-50 by resolution (r=2)	16.4B	77.5%
ResNet-50 compound scale	16.7B	78.8%

아키텍처

- MnasNet과 동일한 search space를 사용해서 찾은 구조이다.



성능

Table 2. EfficientNet Performance Results on ImageNet (Howard et al., 2018). All EfficientNet models are scaled from our baseline EfficientNet-B0 using different compound coefficients α, β, γ . Coefficients with smaller top-1 test accuracy are pruned at training. In the table, the top-1 test accuracy is shown in bold. The top-1 test accuracy is shown in bold. The top-1 test accuracy is shown in bold.

Model	Top-1 Acc.	Top-5 Acc.	FLOPs	Params	Model Size
EfficientNet-B0	74.5%	92.0%	1.0B	5.3M	5.3M
EfficientNet-B1	76.1%	93.1%	1.0B	5.3M	5.3M
EfficientNet-B2	77.1%	94.1%	1.0B	5.3M	5.3M
EfficientNet-B3	78.1%	95.1%	1.0B	5.3M	5.3M
EfficientNet-B4	79.1%	96.1%	1.0B	5.3M	5.3M
EfficientNet-B5	80.1%	97.1%	1.0B	5.3M	5.3M
EfficientNet-B6	81.1%	98.1%	1.0B	5.3M	5.3M
EfficientNet-B7	82.1%	99.1%	1.0B	5.3M	5.3M
EfficientNet-B8	83.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B9	84.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B10	85.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B11	86.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B12	87.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B13	88.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B14	89.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B15	90.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B16	91.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B17	92.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B18	93.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B19	94.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B20	95.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B21	96.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B22	97.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B23	98.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B24	99.1%	100.0%	1.0B	5.3M	5.3M
EfficientNet-B25	100.0%	100.0%	1.0B	5.3M	5.3M




Figure 5. FLOPs vs. ImageNet Accuracy – Similar to Figure 1 except it computes FLOPs rather than model size.

[illegible]