


Attention 함수

- Attention의 시작은 여기서다.
- 기존의 번역은 규칙을 기반으로 번역하는 SMT (Statistical Machine Translation)를 사용했다.
- RNN, LSTM을 활용한 번역방법 NMT (Neural Machine Translation) 방법이 나왔다.
- NMT 같은 경우 입력 데이터 길이가 길든 짧은 Context Vector의 길이는 고정에서 긴문장이 나오면 힘들었다.
- 논문에서는 모델이 다음에 생성할 단어와 관련이 있는 입력 시퀀스에 주목하는 방법을 제안했다.
- ↳ 이때 어떤 입력 시퀀스에 주목 하는지는 각 step으로 정해진다.

Attention Mechanism



Decoder

$$P(y_i | y_1, \dots, y_{i-1}, x) = g(y_{i-1}, s_i, c_i)$$

- Decoder 쪽의 hidden state
- i번째 RNN의 hidden state $\rightarrow s_i = f(s_{i-1}, y_{i-1}, c_i)$
- RNN의 i-1 번째 Output

• Context Vector로 기존 RNN의 고정 Context vector 란은 다르다. T시점, T+2 ... 등 시점마다 다른 Context Vector를 가진다.

$c_i = \sum_{j=1}^{T_x} \alpha_{ij} h_j$
Encoder의 hidden vector

$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})}$
지수 함수

$e_{ij} = a(s_{i-1}, h_j)$
연산도 함수 (Alignment function)

$a(s_{i-1}, h_j) = V_a^T \tanh(W_a s_{i-1} + U_a h_j)$
입력 단어 정보를 attention에 맞게 만들기 위한 공유가중치

$i-1$ 번째 출력 단어 정보를 attention에 맞게 만들기 위한 공유가중치

둘의 관련성을 하나의 숫자 (스칼라)로 압축 시키는 공유가중치

α_{ij} : softmax로 정규화된 집중도 (확률) (Attention Probability)

T_x : time step의 줄임말로 T_x 는 입력문자 x의 길이를 나타낸다. (나는, A, 광, 마 → 3)

T_y : 출력문자 y의 길이를 나타낸다. (I, am, human → 3)

e_{ij} : i번째 hidden state와 j번째 input vector의 alignment score

$$P(y_i | y_1, \dots, y_{i-1}, x) = g(y_{i-1}, s_i, c_i)$$

$$= \text{softmax}(W_o z_i)$$

$$= \text{softmax}(W_o \cdot \text{maxout}(W_s s_i + W_c c_i + W_y e(y_{i-1})))$$


↳ hidden unit 두 개씩 묶어 큰 값만 통과시키는 비선형 함수 (차원 축소점용)

예) 위에식결과가 $[1.0, -100], [-100, 17.0]$ 이면 $(1.0, 17.0)$ 이 나온다.

→ 어휘(V)마다 값이 다르다.

수식을 흐름에 맞춰서 설명

Illustrated Attention



①

최종적으로 모든 encoding에 있는 x 와 현재시점 t 의 바로전 단계 출력을 모두 고려 했을 때
현재시점의 출력 y_t 의 확률값을 알고자 한다.

수식

$$\begin{aligned}
 P(y_t | y_1, \dots, y_{t-1}, x) &= g(y_{t-1}, s_t, c_t) \\
 &= \text{softmax}(w_o z_t) \\
 &= \text{softmax}(w_o \cdot \text{maxout}(w_s s_t + w_c c_t + w_y e(y_{t-1}))) \\
 &= \frac{\exp([w_o \cdot \text{maxout}(w_s s_t + w_c c_t + w_y E(y_{t-1}))]_i)}{\sum_{j=1}^{|V|} \exp([w_o \cdot \text{maxout}(w_s s_t + w_c c_t + w_y E(y_{t-1}))]_j)}
 \end{aligned}$$

$\hookrightarrow$ RNN의 $i-1$ 번째 output
 $\hookrightarrow$ 각시점 Context vector
 $\hookrightarrow$ Decoder의 hidden state

②

단순히 하나의 벡터로 합된다.

$$y_{t-1} (620 \text{차원}) + \text{Context} (1000 \text{차원}) = 1620 \text{차원}$$

③

인코더의 hidden vector와 Attention score의 weighted sum

$$c_i = \sum_{j=1}^T \alpha_{ij} \cdot h_j$$

수식의 자세한 점은 위에

④

Attention score를 구하는 부분으로

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^T \exp(e_{ik})} \quad e_{ij} = a(s_{i-1}, h_j) \quad a(s_{i-1}, h_j) = V_a^T \tanh(W_a s_{i-1} + U_a h_j)$$