

ALBEF (Align before Fuse)




Figure 1: **Illustration of ALBEF.** It consists of an image encoder, a text encoder, and a multimodal encoder. We propose an image-text contrastive loss to align the unimodal representations of an image-text pair before fusion. An image-text matching loss (using in-batch hard negatives mined through contrastive similarity) and a masked-language-modeling loss are applied to learn multimodal interactions between image and text. In order to improve learning with noisy data, we generate pseudo-targets using the momentum model (a moving-average version of the base model) as additional supervision during training.

기본 논문에서 아쉬웠던점

-문제①: 기본 VLP (Vision-Language Pre-training) 모델은 이미지와 텍스트를 align 하기전에 fusion을 바로 해버림

⇒ 결과: Cross-modal representation 품질 저하 → 서로 다른 데이터 (이미지/텍스트)를 같은 공간에서 비교가능한 벡터 표현



-문제②: 다른 VLP (OS (AR) 같은 모델은 객체 탐지를 사용했다.

⇒ 결과: Annotation 비용이 크고 해상도 이미지와 연산비용이 높았다.

-문제③: 웹에서 수집한 데이터는 noisy가 심해서 MLM (Masked Language Modeling)이 noisy text에 overfit하여 일반화 성능 저하

→ 문장의 일부 단어로 거르고 그만큼 맞추도록 학습하는 방식

(ALBEF에서는 이미지와 텍스트가 동시에 들어갔는데 이때 Mask 해서 이미지 정보까지 활용해서 단어 예측)

ALBEF에서는

- Fusion 하기전에 Unimodal 표현을 IT-Loss [Image-Text-Contrastive]로 먼저 정렬

⇒ Multimodal 학습 효율 향상

- 객체 탐지를 없애고, 이미지는 DINO로 인코딩, 텍스트도 BERT로 인코딩 → 이후에 Cross-Modal Attention으로 둘을 연결


⇒ annotation 비용 절감, 속도 증가

- MoD (Momentum Distillation) 사용해서 노이즈 많은 웹데이터를 학습에 사용가능하게 만든다.

⇒ Noisy 웹데이터 (Image, Text)를 Momentum Model에 넣어 생성한 Pseudo-target으로 만들어 학습모델을 soft supervision 학습전법

⇒ 일반화 성능 향상

→ 정답을 확률분포 (soft Label)로 주는 학습방법



큰 흐름

-ITC [Image-Text Contrastive Loss]

- 목적: 합쳐기 전에 유니모달 표현 정렬
- 방법: 매칭된 이미지-텍스트 쌍은 가깝게, 매칭되지 않은 쌍은 멀게

-ITM [Image-Text Matching Loss]

- 목적: 멀티모달 상호작용 학습
- 특징: 대조 유사도를 통해 배치 내 하드 네거티브 마이닝 (비도플래에 아닌 것)
- 과정: ITC로 유사도 계산 → 가장 도전적인 네거티브 샘플 선택 → 이런 블록 문제로 매칭 반복 판단.

-MLM [Masked Language Modeling Loss]

- 목적: 이미지 정보를 활용한 언어 이해 학습
- 방법: 텍스트의 일부 단어를 마스킹하고 나머지 정보 예측
- ➡ 일정 문장을 가지고, 맥락 단어와 가린 문장을 비교해서 빈공간을 맞추는거

-Momentum

- 목적: 웨테이터는 Noisy가 많아서 노이즈에 더 강건한 학습을 하게위해사용
- 방법: ① 노이즈 데이터를 모멘텀 모델에 얹적
- ② 모멘텀 모델은 비교적 안정적인 예측을 함 (소프트라벨)
- ③ 하드라벨 대신 소프트 라벨로 학습
- 업데이트: $\theta_{momentum} = \alpha \times \theta_{momentum} + (1-\alpha) \times \theta_{current}$
- ➡ $\alpha = 0.999$ (대부분 일정해)
- 하드: [0 0 1 0]
소프트: [0.1 0.2 0.7] → 불확실성 반영

아키텍처

-이미지 인코더

- 모델: ViT-B/16, 레이어 수: 12층, 초기화: ImageNet-1k에서 사전 훈련된 가중치 사용

-텍스트 인코더


- 모델: 6층 Transformer, 초기화: BERT-base의 원 (6층 가중치 사용)

-멀티모달 인코더

- 모델: 6층 Transformer, 초기화: BERT-base의 마지막 6층 가중치 사용

-BERT를 나눠서 사용하는 이유

- 저수준(텍스트 인코더) = 언어의 기본구조 파악 (문법, 구문 이해 - 단어가 관계 파악)
- 고수준(멀티모달 인코더) = 의미 통합 및 추론, 복잡한 멀티모달 관계 모델링



ITC-Loss

• 이미지와 텍스트가 얼마나 유사한지 계산하는 Loss

$$\text{Cross-Entropy} \quad | - \log(p_{ci})$$

정답 분포와 예측분포 사이의 차이(오차)를 계산

$$L_{itc} = \frac{1}{2} \mathbb{E}_{(I,T) \sim D} [H(y^{i2t}(I), p^{i2t}(I)) + H(y^{t2i}(T), p^{t2i}(T))]$$

데이터셋 D에서
이미지 I와 텍스트 T 샘플
무작위로 뽑아 기대값(평균) 계산

각각 이미지 → 텍스트
텍스트 → 이미지의 ONE Hot 형태 정답
[정답 샘플 1, 나머지는 0]

모델이 예측한 유사도 기반
확률 분포 softmax로 계산된 확률값

$p^{i2t}(I)$ 와 $p^{t2i}(T)$ 추가설명

- $p^{i2t}(I)$ = 이미지가 주어졌을 때 텍스트가 정답일 확률
- $p^{t2i}(T)$ = 텍스트가 주어졌을 때 이미지가 정답일 확률
- m = m번째 텍스트 or m번째 이미지
- γ (타우) = 상수값
크면: 퍼지고 안정적인 학습
작으면: 날카롭고 확실하게 결론냄

$$p_m^{i2t}(I) = \frac{\exp(s(I, T_m)/\gamma)}{\sum_{m=1}^M \exp(s(I, T_m)/\gamma)}, \quad p_m^{t2i}(T) = \frac{\exp(s(T, I_m)/\gamma)}{\sum_{m=1}^M \exp(s(T, I_m)/\gamma)}$$


유사도 계산

$$s(I, T) = v^i \cdot t^t, \quad s(T, I) = t^i \cdot v^i$$

visual의 ⑩ 의미이다

※ 정해진 데이터에서 더 많은 학습샘플 뽑아내기

- 기존의 target은 Positive만 '1' 나머지는 '0'으로 되어 있다 보니 너무 hard 하다.
- Momentum Encoder에 '이미지' or '텍스트'를 넣어서 나오는 target은 확률 분포로 나와 데이터가 soft해진다.
- 위와 같은 이유로 ITC-Loss에 넣어 사용함으로써 모델의 일반화가 상승한다.



MLM (Masked Language Modeling)

- 입력 문장의 15% 정도를 무작위로 선택해 [Mask] 토큰으로 가린다.

$$L_{mlm} = \mathbb{E}_{(I, \hat{I}) \sim D} H(y^{msk}, p^{msk}(I, \hat{I}))$$

추가설명

입력가 가려진 (Masked) 테스트

모델이 예측한 마스크된 단어의 확률 분포

$$H(y^{msk}, p^{msk}(I, \hat{I}))$$

- ① I am a [Mask] + [이미지] 가 만들어지면
- ② 모델은 이미지와 위의 마스크된 문장을 보고 [Mask] 가 무엇인지 확률 분포를 도출 한다.
- ③ 예) $p = [\text{boy} : 0.7, \text{girl} : 0.3]$
- ③ H (크로스엔트로피)는 정답 $y^{msk} = \text{boy}$ (one-hot 형태)와 예측값의 Loss를 뽑아낸다.

ITM (Image-Text Matching)

- IT (만 하면 모델은 세부적인 특징을 이해하기 어렵다.
- 예) (트럭 → 트럭) 2개 가 어느정도 정답으로 나올수 있다.
- 그래서 ITM에서는 "정말로 이미지와 문장이 정확히 매칭되는지 binary classification으로 학습한다.
- Positive, Negative 쌍을 만들어서 학습을 진행한다.

예)

			...
트럭 차량	0.61	0.87	→ 정답을 제외한 이미지 또는 텍스트를 가져고 가장 높은 데이터를 Negative로 정답은 Positive로 학습한다.
파랑 차량	0.91	0.93	
	0.42	0.3	

$$L_{itm} = \mathbb{E}_{(I, T) \sim D} H(y^{itm}, p^{itm}(I, T))$$

Total Loss

- 3개의 Loss를 합쳐서 사용한다.

$$L = L_{ITC} + L_{ITM} + L_{MLM}$$

- L_{ITC} = 이미지와 텍스트 쌍의 유사도 조절 (대조학습)
- L_{ITM} = 이미지와 텍스트가 짝인지 불확 (매칭 판단능력 강화)
- L_{MLM} = 문장에서 마스크된 단어 예측 (언어 이해 강화)

GPT 3.2

}