

머신러닝분야에서는 하나의 표준 데이터만 가지고도, 전체 모집단을 통계적인 특성을 측정하려는 방법을 말한다.

BLIP-1 (Bootstrapping Language-Image Pre-training)

들어가면서

- 기존의 CLIP과 같은 VLP (Vision-Language Pre-training) 모델들로 학습시키기 위해 Large web scale 데이터로 학습시켰다.
- 이런 데이터의 문제는 image와 Text에 noise가 많다는 한계점이 존재한다.
 - 그래서 BLIP은 잘못된 캡션을 걸러내고, 새로운 캡션을 사용하여 데이터셋을 bootstrapping 하는 CapFill 구조를 제시했다.
- 기존에 CLIP은 Image-Text Relevance와 Image Understanding에 강하지만 텍스트 생성능력이 없다.
- 그래서 BLIP은 이미지 기반 텍스트 생성, 텍스트로 이미지를 검색하는 MED 구조인 VLP를 만들었다.

Loss

- BLIP은 ALBEF라는 논문에서 제시한 모델과 유사한 구조를 가지고 있다.
- Image, Text 데이터를 encoder(ViT, BERT 등)로 인코딩하고, task에 맞는 Loss를 활용한다.

ITC (Image-Text Contrastive Loss)

- Contrastive Learning의 개념을 그대로 도입하여, 같은 Image, Text

ALBEF