

CLIP

2021년 당시 비전과 자연어 분야 모습

비전

- 2021년 이전은 효율적이고 깊은 모델을 어떻게 만들지 고민했다. 또는 Attention 모듈을 적용시키기도 했다.

↳ Inception, ResNet

↳ SENet, BAM

- 2021년 후반 Transformer 구조를 적용시키는게 트렌드였다

↳ Vision Transformer, Image GPT

- 위에처럼 다양한 시도를 했지만 고질적인 문제가 있었다.

① 일반화 능력 부족

② 작은 노이즈에 취약하다.

언어 모델 (LM)

- 2017년까지만 해도 seq2seq 방식의 한계로 극심했지만 2017년 이후에 Transformer 구조가 들어오고

기준에 긴 문장을 소화하지 못하는 seq2seq 구조와 달리 긴 문장도 효과적으로 처리할 수 있게 되었다.

그래서 나온게 GPT-1, GPT-2, BERT 등 초대 언어 모델 (LLM) 이 나온 거다.

CLIP 맛보기

이론의 저자들은 비전 모델들의 일반화 부족 문제를 해결하기 위해 자연어 학습 데이터도 사용하기로 한다.

- 위에서 자연어를 Label로 사용함으로써 zero-shot 분류가 가능해진다.

- 데이터는 이미지와 설명이 쌍으로 여러어져 있는 데이터 4억장을 준비했다.

↳ 데이터가 너무 많아서 잘못된 데이터가 있어도 Contrastive Learning 덕분에 해결했다.


Contrastive Learning — SimCLR 논문 참고

- 기존 ImageNet 데이터셋처럼 cross Entropy Loss로 학습할 수 없기 때문에 Contrastive Learning을 사용한다.

↳ 왜냐하면 자연어는 Label과 달리 특정 개수가 구별되어 있지 않기 때문

- Contrastive Learning은 대조 학습으로서 매칭되는 데이터 Feature 들끼리는 가까워지고

나머지 Feature 들 끼리는 멀어지도록 학습하는 방법이다.



여기서 말하는 N은 N개의 이미지, 텍스트이다.

여기서 feature는 고차원 벡터값이다.

- ① 이미지를 Image Encoder, 텍스트를 Text Encoder로 Feature를 추출해준다.

- ② 두개의 Feature를 위와 같이 나열한다.

- ③ 여기서 파랑색처럼 같은 의미를 나타내는 내적값은 방향이 같아지도록

그 외에 빨간색처럼 다른 의미를 나타내는 내적값들은 방향이 달라지도록 한다.

- ④ 이때 사용하는 것이 Cosine Similarity 사용해서 Image Encoder와 Text Encoder를 학습한다.

• 다양한 vision Model 사용이 가능하지만


수정이 들어간 5가지 종류의 ResNet

기준 3성 거의 그대로 사용하는 ViT 3종 사용

CLIP_Zero shot 푸른 방법

- Zero shot이란 한번도 학습하지 않은 문제를 맞추는 방법이다.
- 기존 지도 학습은 class가 정해져 있어서 새로운 class를 예측할려면 다시 처음부터 학습해야 한다.

방법




- ① 학습 때처럼 1개 이미지에서 고차원 벡터값이 나온다.
- ② 여러개의 텍스트들은 TextEncoder를 통해 여러개의 고차원 벡터가 나온다.
- ③ 각각 cosine similarity를 측정해준다.
- ④ 이미지를 가장 잘 설명한 Text가 값이 크게 나온다.


CLIP을 Linear Probing 학습

- Zero-shot 방법 만으로도 충분하지만 특정분야에 성능을 더 올리는 방법이다.
- 이미지 예측 모델에서 마지막 feature에다가 Linear공간을 추가한다.
- 다른 부분(기본 구조)는 전부 고정시키고 Linear공간만 학습을 다시한다.
- 아주 간단하다.


성능 비교



CLIP이 좋은 성능을 보인다.



이정도 성능 보임다.



모든 데이터셋에서 학습사항에 좋은 성능

Zero-shot CLIP (학습X) 결과

학습한 ResNet 50이랑 성능비교

다른 모델은 2, 4, 8, 16만 class만들어서

CLIP (학습X) 비교

CLIP도 학습시켜보고 안하면 가장 비교